

# TAIL — INTRODUÇÃO À MATEMÁTICA PARA INTELIGÊNCIA ARTIFICIAL

Diretoria de Matemática - Tail

11/09/2020

## 1 Introdução a matrizes

Uma matriz  $A_{m \times n}$  é um arranjo retangular com  $m$  linhas e  $n$  colunas da forma

$$A_{m \times n} = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{vmatrix} \quad (1)$$

onde  $a_{ij} \in \mathbb{R}$ ,  $i = 1, 2, \dots, m$  e  $j = 1, 2, \dots, n$ .

A  $i$ -ésima linha da matriz  $A$  é matriz  $1 \times n$ , sendo considerado como vetor

$$Li = \begin{vmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \end{vmatrix} \quad (2)$$

e a  $j$ -ésima coluna da matriz  $A$  é matriz  $m \times 1$ , também considerado como um vetor

$$Cj = \begin{vmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{vmatrix} \quad (3)$$

Podemos também dizer que uma matriz é formada por  $m$  vetores horizontais e  $n$  vetores verticais, normalmente, vemos a primeira forma,  $m$  vetores com  $n$  elementos cada.

**Definição 1.1** (diagonal principal). A *diagonal principal* de uma matriz quadrada  $A$  é formada pelos componentes  $a_{ij}$  onde  $i = j$ .

**Exemplo 1.1.1.** :

$$\begin{vmatrix} \mathbf{a_{11}} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & \mathbf{a_{22}} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & \mathbf{a_{33}} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & a_{m3} & \cdots & \mathbf{a_{mn}} \end{vmatrix} \quad (4)$$

**Exemplo 1.1.2.** :

$$\begin{vmatrix} \mathbf{1} & -45 & 10 \\ 4 & \mathbf{2} & 3 \\ 7 & 25 & \mathbf{3} \end{vmatrix} \quad (5)$$

**Exemplo 1.1.3.** :

$$\begin{vmatrix} \mathbf{2} & -45 & 10 & 3 \\ 4 & \mathbf{3} & 3 & 7 \\ 7 & 25 & \mathbf{8} & 0 \\ 1 & 2 & 5 & \mathbf{1} \end{vmatrix} \quad (6)$$

**Definição 1.2** (matriz diagonal). É uma matriz quadrada formada por componentes  $a_{ij} = 0$  onde  $i \neq j$ .

**Exemplo 1.2.1.** :

$$\begin{vmatrix} \mathbf{a}_{11} & 0 & 0 & \cdots & 0 \\ 0 & \mathbf{a}_{22} & 0 & \cdots & 0 \\ 0 & 0 & \mathbf{a}_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \mathbf{a}_{mn} \end{vmatrix} \quad (7)$$

**Exemplo 1.2.2.** :

$$\begin{vmatrix} \mathbf{3} & 0 & 0 \\ 0 & \mathbf{4} & 0 \\ 0 & 0 & \mathbf{2} \end{vmatrix} \quad (8)$$

**Exemplo 1.2.3.** :

$$\begin{vmatrix} \mathbf{3} & 0 & 0 & 0 \\ 0 & \mathbf{4} & 0 & 0 \\ 0 & 0 & \mathbf{0} & 0 \\ 0 & 0 & 0 & \mathbf{7} \end{vmatrix} \quad (9)$$

**Definição 1.3** (Matriz Identidade). A matriz identidade é uma matriz diagonal especial, formada por apenas 1s e 0s. Desse modo:  $\forall a_{ij} \in \mathbb{R}$  se  $i = j$ ,  $a_{ij} = 1$  e se  $i \neq j$ ,  $a_{ij} = 0$ .

**Exemplo 1.3.1.**

$$I_M = \begin{vmatrix} \mathbf{1} & 0 & 0 & \cdots & 0 \\ 0 & \mathbf{1} & 0 & \cdots & 0 \\ 0 & 0 & \mathbf{1} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \mathbf{1} \end{vmatrix} \quad (10)$$

**Exemplo 1.3.2.**

$$I_2 = \begin{vmatrix} \mathbf{1} & 0 \\ 0 & \mathbf{1} \end{vmatrix} \quad (11)$$

**Exemplo 1.3.3.**

$$I_3 = \begin{vmatrix} \mathbf{1} & 0 & 0 \\ 0 & \mathbf{1} & 0 \\ 0 & 0 & \mathbf{1} \end{vmatrix} \quad (12)$$

Além das definições, podemos realizar operações básicas com matrizes como **Multiplicação por escalar** e **Soma de matrizes**. Vamos definir  $\mathbf{A}_{m \times n}$ , com  $m$  linhas e  $n$  colunas e  $\mathbf{B}_{m \times n}$ , com as mesmas dimensões de  $\mathbf{A}$ ,  $\forall \alpha \in \mathbb{R}$ , ou seja, alpha pertencente ao conjunto dos números *Reais*, tal que:

$$\mathbf{A} = \begin{vmatrix} a_{11} & a_{21} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m1} & \cdots & a_{mn} \end{vmatrix} \quad (13)$$

$$\mathbf{B} = \begin{vmatrix} b_{11} & b_{21} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m1} & \cdots & b_{mn} \end{vmatrix} \quad (14)$$

Podemos definir  $\alpha \cdot \mathbf{A}$  da seguinte forma:

$$\alpha \cdot \mathbf{A} = \alpha \cdot \begin{vmatrix} a_{11} & a_{21} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m1} & \cdots & a_{mn} \end{vmatrix} = \begin{vmatrix} \alpha \cdot a_{11} & \alpha \cdot a_{21} & \cdots & \alpha \cdot a_{1n} \\ \alpha \cdot a_{21} & \alpha \cdot a_{22} & \cdots & \alpha \cdot a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha \cdot a_{m1} & \alpha \cdot a_{m1} & \cdots & \alpha \cdot a_{mn} \end{vmatrix} \quad (15)$$

Como pode ver, a multiplicação de um escalar pela matriz dar-se termo a termo, multiplicado pelo escalar. Abaixo definimos a soma das matrizes  $\mathbf{A}$  e  $\mathbf{B}$  também termo a termo, da seguinte forma:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m1} & \cdots & a_{mn} \end{bmatrix} + \begin{bmatrix} b_{11} & b_{21} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m1} & \cdots & b_{mn} \end{bmatrix} = \quad (16)$$

$$= \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \cdots & a_{1n} + b_{1n} \\ a_{21} + b_{21} & a_{22} + b_{22} & \cdots & a_{2n} + b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} + b_{m1} & a_{m2} + b_{m2} & \cdots & a_{mn} + b_{mn} \end{bmatrix} \quad (17)$$

Abaixo seguem as propriedades para operações com matrizes e valores escalares.

**Propriedade 1.1** (Propriedade Associativa).  $(A + B) + C = A + (B + C)$ ,  $\forall A, B, C \in \mathbb{R}^{m \times n}$  (para todos).

**Propriedade 1.2** (Matriz Nula). Existe  $O \in \mathbb{R}^{m \times n}$  tal que  $A + O = A$ ,  $\forall A \in \mathbb{R}^{m \times n}$ .

**Propriedade 1.3** (Matriz Oposta).  $\forall A \in \mathbb{R}^{m \times n}$ , existe  $-A \in \mathbb{R}^{m \times n}$  tal que  $A + (-A) = O$ , onde  $-A = [-a_{ij}]$ .

**Propriedade 1.4** (Propriedade da Soma).  $A + B = B + A$ ,  $\forall A, B \in \mathbb{R}^{m \times n}$ .

**Propriedade 1.5** (Propriedade Distributiva da Multiplicação).  $(a + b)A = aA + bA$ ,  $\forall a, b \in \mathbb{R}$  e  $A \in \mathbb{R}^{m \times n}$ .

**Propriedade 1.6** (Propriedade Distributiva da Multiplicação 2).  $a(A + B) = aA + aB$ ,  $\forall a \in \mathbb{R}$  e  $A, B \in \mathbb{R}^{m \times n}$ .

**Propriedade 1.7** (Propriedade da igualdade).  $a(A + B) = aA + aB$ ,  $\forall a \in \mathbb{R}$  e  $A, B \in \mathbb{R}^{m \times n}$ .

**Propriedade 1.8** (Propriedade da igualdade).  $1 \cdot A = A$ ,  $\forall A \in \mathbb{R}^{m \times n}$ .

## 1.1 Multiplicação de matrizes

Sejam  $A = [a_{ij}] \in \mathbb{R}^{m \times n}$  e  $B = [b_{ij}] \in \mathbb{R}^{n \times p}$ . O produto de  $A$  por  $B$ , em símbolos,  $AB$ , é definido como:

$$A_{3 \times 2} \times B_{2 \times 1} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \times \begin{bmatrix} b_{11} \\ b_{21} \end{bmatrix} = \begin{bmatrix} (a_{11} \cdot b_{11}) + (a_{12} \cdot b_{21}) \\ (a_{21} \cdot b_{11}) + (a_{22} \cdot b_{21}) \\ (a_{31} \cdot b_{11}) + (a_{32} \cdot b_{21}) \end{bmatrix} \quad (18)$$

A operação pode parecer desafiadora a primeira vista, porém o passo a passo a ser seguido é simples

O mais importante é ter atenção nas dimensões das matrizes,  $\dim(A)$  é  $3 \times 2$ , e  $\dim(B)$  é  $2 \times 1$ , para podermos multiplicá-las o número de colunas da primeira deve ser igual ao número de linhas da segunda, em termos matemáticos é comum ver:  $A_{m \times n} \cdot B_{n \times p}$ , o que resulta numa matriz  $C_{m \times p}$ , ou seja, nesse exemplo a matriz resultante tem dimensões  $\dim(C) = 3 \times 1$ .

O passo a passo a ser seguido é:

1. Identificar a primeira linha da primeira matriz e a primeira coluna da segunda matriz
2. Multiplicar o primeiro elemento da linha com o primeiro elemento da coluna
3. Somar as multiplicações até o n-ésimo termo das matrizes
4. Repetir com o restante da matriz

**Exemplo 1.3.4.**

$$A_{3 \times 2} \times B_{2 \times 1} = \begin{vmatrix} \textcolor{red}{3} & \textcolor{brown}{-1} \\ 0 & 2 \\ 1 & 1 \end{vmatrix} \times \begin{vmatrix} \textcolor{blue}{1} \\ \textcolor{green}{2} \end{vmatrix} = \begin{vmatrix} (\textcolor{red}{3} \cdot \textcolor{blue}{1}) + (\textcolor{brown}{-1} \cdot \textcolor{green}{2}) \end{vmatrix} \quad (19)$$

$$A_{3 \times 2} \times B_{2 \times 1} = \begin{vmatrix} 3 & -1 \\ \textcolor{red}{0} & \textcolor{brown}{2} \\ 1 & 1 \end{vmatrix} \times \begin{vmatrix} \textcolor{blue}{1} \\ \textcolor{green}{2} \end{vmatrix} = \begin{vmatrix} 1 \\ (\textcolor{red}{0} \cdot \textcolor{blue}{1}) + (\textcolor{brown}{2} \cdot \textcolor{green}{2}) \end{vmatrix} \quad (20)$$

$$A_{3 \times 2} \times B_{2 \times 1} = \begin{vmatrix} 3 & -1 \\ 0 & 2 \\ \textcolor{red}{1} & \textcolor{brown}{1} \end{vmatrix} \times \begin{vmatrix} \textcolor{blue}{1} \\ \textcolor{green}{2} \end{vmatrix} = \begin{vmatrix} 1 \\ 4 \\ (\textcolor{red}{1} \cdot \textcolor{blue}{1}) + (\textcolor{brown}{1} \cdot \textcolor{green}{2}) \end{vmatrix} \quad (21)$$

$$A_{3 \times 2} \times B_{2 \times 1} = \begin{vmatrix} 3 & -1 \\ 0 & 2 \\ 1 & 1 \end{vmatrix} \times \begin{vmatrix} 1 \\ 2 \end{vmatrix} = \begin{vmatrix} 1 \\ 4 \\ 3 \end{vmatrix} \quad (22)$$

Desse modo, se  $AxB$  for uma multiplicação válida não implica que  $BxA$  também a seja, apenas se  $A$  e  $B$  forem matrizes quadradas

## 1.2 Determinante de uma matriz

**Definição 1.4** (Determinante). É um número associado à matriz quadrada, que envolve operações incluindo todos os elementos desta

**Exemplo 1.4.1** (Determinante de matriz 2x2). *Simplemente multiplicamos os valores da diagonal principal e subtraímos o valor da multiplicação dos elementos restantes*

$$\det[A] = \det \begin{vmatrix} 1 & 2 \\ 2 & 0 \end{vmatrix} = (1 \cdot 0) - (2 \cdot 2) = -4 \quad (23)$$

**Exemplo 1.4.2** (Determinante de matriz 3x3). Método de Sarrus

$$\det[A] = \det \begin{vmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 0 & 1 & 1 \end{vmatrix} \quad (24)$$

"Duplica-se" as duas primeiras colunas a direita da matriz para facilitar o agrupamento dos elementos

$$\begin{vmatrix} 1 & 2 & 3 & 1 & 2 \\ 2 & 0 & 1 & 2 & 0 \\ 0 & 1 & 1 & 0 & 1 \end{vmatrix} \quad (25)$$

Multiplica-se as três diagonais da esquerda para a direita e as três da direita para a esquerda. Por fim, soma-se os três primeiros resultados e subtrai-se a soma dos outros três.

$$\left[ (1 \cdot 0 \cdot 1) + (2 \cdot 1 \cdot 0) + (3 \cdot 2 \cdot 1) \right] - \left[ (2 \cdot 2 \cdot 1) + (1 \cdot 1 \cdot 1) + (3 \cdot 0 \cdot 0) \right] \quad (26)$$

$$(0 + 0 + 6) - (4 + 1 + 0) = 6 - 5 = 1 \quad (27)$$

### 1.3 Outras operações de matrizes

**Definição 1.5** (Matriz transposta). A matriz transposta de uma matriz é obtida escrevendo as linhas da matriz como colunas, ou simplesmente,

**Exemplo 1.5.1.**

$$A = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix} \quad A^T = \begin{vmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{vmatrix} \quad (28)$$

**Definição 1.6** (Matriz Adjunta). A matriz adjunta de uma matriz A - adj(A) é a transposta da matriz dos cofatores  $A_{ij}$  de A.

**Definição 1.7** (Matriz Inversa). A matriz inversa tem a propriedade de quando multiplicada a matriz base resultar na matriz identidade.

$$A^{-1} \times A = I \quad (29)$$

Ela é definida como:

$$A^{-1} = \frac{1}{\det(A)} \cdot \text{adj}(A) \quad (30)$$

*Há outra forma de adquirir a matriz inversa, de maneira bem mais simples e intuitiva:*

**Exemplo 1.7.1.** Começamos com o seguinte sistema linear: (Sendo A uma matriz quadrada e I a matriz identidade de mesma dimensão que A)

$$A \times A^{-1} = I \quad (31)$$

*Sabemos os valores de A, sabemos também os valores de I, então usaremos as regras simples da multiplicação de matriz para achar  $A^{-1}$*

$$A \times A^{-1} = \begin{vmatrix} 3 & -1 & 0 \\ 0 & 2 & 1 \\ 1 & 1 & 0 \end{vmatrix} \times \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = \begin{vmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{vmatrix} \quad (32)$$

*O resultado da multiplicação é esse:*

$$\begin{vmatrix} (3 \cdot a_{11} + (-1) \cdot a_{21} + 0 \cdot a_{31}) & (3 \cdot a_{12} + (-1) \cdot a_{22} + 0 \cdot a_{32}) & (3 \cdot a_{13} + (-1) \cdot a_{23} + 0 \cdot a_{33}) \\ (0 \cdot a_{11} + 2 \cdot a_{21} + 1 \cdot a_{31}) & (0 \cdot a_{12} + 2 \cdot a_{22} + 1 \cdot a_{32}) & (0 \cdot a_{13} + 2 \cdot a_{23} + 1 \cdot a_{33}) \\ (1 \cdot a_{11} + 1 \cdot a_{21} + 0 \cdot a_{31}) & (1 \cdot a_{12} + 1 \cdot a_{22} + 0 \cdot a_{32}) & (1 \cdot a_{13} + 1 \cdot a_{23} + 0 \cdot a_{33}) \end{vmatrix} \quad (33)$$

*Agora igualamos cada coluna da matriz multiplicação a cada coluna da matriz identidade, formando os três sistemas lineares.*

*Primeira coluna:*

$$\begin{vmatrix} (3 \cdot a_{11} + (-1) \cdot a_{21} + 0 \cdot a_{31}) = 1 \\ (0 \cdot a_{11} + 2 \cdot a_{21} + 1 \cdot a_{31}) = 0 \\ (1 \cdot a_{11} + 1 \cdot a_{21} + 0 \cdot a_{31}) = 0 \end{vmatrix} \quad (34)$$

*Segunda coluna:*

$$\begin{vmatrix} (3 \cdot a_{12} + (-1) \cdot a_{22} + 0 \cdot a_{32}) = 0 \\ (0 \cdot a_{12} + 2 \cdot a_{22} + 1 \cdot a_{32}) = 1 \\ (1 \cdot a_{12} + 1 \cdot a_{22} + 0 \cdot a_{32}) = 0 \end{vmatrix} \quad (35)$$

*Terceira coluna:*

$$\begin{vmatrix} (3 \cdot a_{13} + (-1) \cdot a_{23} + 0 \cdot a_{33}) = 0 \\ (0 \cdot a_{13} + 2 \cdot a_{23} + 1 \cdot a_{33}) = 0 \\ (1 \cdot a_{13} + 1 \cdot a_{23} + 0 \cdot a_{33}) = 1 \end{vmatrix} \quad (36)$$

## 1.4 Exemplos

Com tantos conceitos expostos, tantas definições, fica a pergunta: Onde eu usarei isso? Aqui está um exemplo claro do uso da matemática, de modo bem simples, de um método estatístico muito frequente para resolução de problemas lineares: A Regressão Linear.

### 1.4.1 Regressão Linear

Na estatística, a regressão é uma equação utilizada para estimar valores para uma variável  $Y$  (Variável dependente ou explicada), dado um valor para  $X$  (Variável independente ou explicativa). A regressão linear tem esse nome "linear", pelo fato de querer assumir uma relação Linear entre as variáveis, ou seja,  $Y$  é uma função linear, tendo alguns valores como parâmetros. A equação abaixo define a expressão para regressão linear múltipla, escrita em sua forma matricial:

$$Y = X \cdot \hat{\beta}$$

Onde podemos definir  $Y$  como uma matriz  $n \times 1$ , ou também, como simplesmente um vetor com  $n$  entradas;  $X$ , uma matriz de dimensões  $n \times p + 1$  (sendo a primeira coluna preenchida sempre com 1s);  $\beta$ , uma matriz de dimensões  $p + 1 \times 1$ , ou um vetor com  $p + 1$  entradas.

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, X = \begin{bmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}, \vec{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} \quad (37)$$

Dado que conhecemos os valores de  $X$  e queremos estimar  $Y$ , apenas nos resta estimar os  $\beta$ , então utilizamos a seguinte expressão para o caso da regressão múltipla:

$$\hat{\beta} = (X^T \cdot X)^{-1} \cdot X^T \cdot Y \quad (38)$$

**Exemplo 1.7.2.** Uma equipe de segurança de redes, decidiu desenvolver várias formas de conter ataques aos servidores e rede, e então decidiram encontrar uma forma de avaliar os mecanismos e estimar um valor para o índice de sucesso dos meios desenvolvidos. Para isso foi desenvolvido um **Índice de sucesso** baseado em dois fatores:

- Tempo de experimento (duração);
- Número de ataques no período.

Logo em seguida, definindo como seria feito o experimento, observaram os seguintes dados amostrais:

Esquema	Nº Ataques	Duração	Índice
A	5	118	8.1
B	13	132	6.8
C	20	119	7.0
D	28	153	7.4
E	41	91	7.7
F	49	118	7.5
G	61	132	7.6
H	62	105	8.0

Logo, dado os dados amostrais, podemos definir  $Y$  e  $X$  da seguinte forma matricial:

$$X = \begin{bmatrix} 1 & 5 & 118 \\ 1 & 13 & 132 \\ 1 & 20 & 119 \\ 1 & 28 & 153 \\ 1 & 41 & 91 \\ 1 & 49 & 118 \\ 1 & 61 & 132 \\ 1 & 62 & 105 \end{bmatrix}, Y = \begin{bmatrix} 8.1 \\ 6.8 \\ 7.0 \\ 7.4 \\ 7.7 \\ 7.5 \\ 7.6 \\ 8.0 \end{bmatrix}$$

Note agora que além desses valores, precisamos realizar operações para a estimativa de  $\beta$ , que são evidenciadas pela equação (38). Vamos por partes, primeiro vamos encontrar a transposta de  $X$ :

$$X = \begin{vmatrix} 1 & 5 & 118 \\ 1 & 13 & 132 \\ 1 & 20 & 119 \\ 1 & 28 & 153 \\ 1 & 41 & 91 \\ 1 & 49 & 118 \\ 1 & 61 & 132 \\ 1 & 62 & 105 \end{vmatrix} \Rightarrow X^T = \begin{vmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 5 & 13 & 20 & 28 & 41 & 49 & 61 & 62 \\ 118 & 132 & 119 & 153 & 91 & 118 & 132 & 105 \end{vmatrix}$$

Então, vamos calcular primeiro  $(X^T \cdot X)^{-1}$ , uma multiplicação matricial como na seção 1.1, logo em seguida, basta calcularmos a inversa do resultado, como na seção 1.3.

$$X^T \cdot X = \begin{vmatrix} 8 & 279 & 968 \\ 279 & 13025 & 33045 \\ 968 & 33045 & 119572 \end{vmatrix} \Rightarrow (X^T \cdot X)^{-1} = \begin{vmatrix} 7.7134 & -0.0227 & -0.0562 \\ -0.0227 & 0.0003 & 0.0001 \\ -0.0562 & 0.0001 & 0.0004 \end{vmatrix}$$

E então, calculamos agora  $X^T \cdot Y$ .

$$X^T \cdot Y = \begin{vmatrix} 60.1 \\ 2118.9 \\ 7247.5 \end{vmatrix}$$

Por fim, temos que  $\hat{\beta}$  é estimado da seguinte forma:

$$\hat{\beta} = (X^T \cdot X)^{-1} \cdot X^T \cdot Y = \begin{vmatrix} 8.37 \\ 0.005 \\ -0.009 \end{vmatrix}$$

Agora que está estimado o  $\hat{\beta}$ , podemos definir o  $\hat{Y}$  estimado pela regressão da seguinte forma:

$$\hat{Y} = X \cdot \hat{\beta} = \begin{vmatrix} 1 & 5 & 118 \\ 1 & 13 & 132 \\ 1 & 20 & 119 \\ 1 & 28 & 153 \\ 1 & 41 & 91 \\ 1 & 49 & 118 \\ 1 & 61 & 132 \\ 1 & 62 & 105 \end{vmatrix} \cdot \begin{vmatrix} 8.37 \\ 0.005 \\ -0.009 \end{vmatrix} = \begin{vmatrix} 7.4 \\ 7.3 \\ 7.4 \\ 7.2 \\ 7.8 \\ 7.6 \\ 7.5 \\ 7.8 \end{vmatrix}$$

## 1.5 Exercícios

**Exemplo 1.7.3** (Soma, Subtração e Multiplicação por escalar). Dadas as matrizes A, B e C

$$A = \begin{vmatrix} 1 & 2 & 3 \\ -4 & 1 & 2 \\ 1 & 1 & 2 \end{vmatrix} \quad B = \begin{vmatrix} 2 & 0 & 3 \\ 5 & 4 & 6 \\ 5 & 1 & 7 \end{vmatrix} \quad C = \begin{vmatrix} 1 & 3 & 4 \\ 1 & 0 & 2 \\ 1 & 2 & 4 \end{vmatrix} \quad (39)$$

Determine:

1.  $A + B$
2.  $B + C$
3.  $A + B - C$
4.  $2A - B + 3C$

**Exemplo 1.7.4** (Multiplicação de matrizes). Dadas as matrizes A, B e C

$$A = \begin{vmatrix} 1 & 2 \\ 0 & 1 \\ 1 & 1 \end{vmatrix} \quad B = \begin{vmatrix} 2 & 1 & 3 \\ 1 & 0 & 2 \end{vmatrix} \quad C = \begin{vmatrix} 2 & 3 & 1 \\ 2 & 0 & 2 \\ 1 & 2 & 4 \end{vmatrix} \quad (40)$$

Determine:

1.  $A \times B$
2.  $B \times A$
3.  $C \times A$
4.  $A \times B \times C$

**Exemplo 1.7.5** (Determinante). Dadas as matrizes A, B e C

$$A = \begin{vmatrix} 1 & 2 & 3 \\ -4 & 1 & 2 \\ 1 & 1 & 2 \end{vmatrix} \quad B = \begin{vmatrix} 2 & 0 & 3 \\ 5 & 4 & 6 \\ 5 & 1 & 7 \end{vmatrix} \quad C = \begin{vmatrix} 1 & 3 & 4 \\ 1 & 0 & 2 \\ 1 & 2 & 4 \end{vmatrix} \quad (41)$$

Determine:

1.  $\det(A)$
2.  $\det(B)$
3.  $\det(C)$
4.  $\det(A \times B)$

**Exemplo 1.7.6** (Inversa). Dadas as matrizes A, B e C

$$A = \begin{vmatrix} 1 & 2 & 3 \\ -4 & 1 & 2 \\ 1 & 1 & 2 \end{vmatrix} \quad B = \begin{vmatrix} 2 & 0 & 3 \\ 5 & 4 & 6 \\ 5 & 1 & 7 \end{vmatrix} \quad C = \begin{vmatrix} 1 & 3 & 4 \\ 1 & 0 & 2 \\ 1 & 2 & 4 \end{vmatrix} \quad (42)$$

Determine:

1.  $A^{-1}$
2.  $B^{-1}$
3.  $C^{-1}$
4.  $(A \times B)^{-1}$



## 2 Introdução à Geometria Analítica

### 2.1 Vetores Unitários Ortogonais


Vamos definir  $\hat{i}$ ,  $\hat{j}$  e  $\hat{k}$  como os vetores unitários ortogonais, ou seja com comprimento de uma unidade de medida (1 u.a) e ortogonais entre eles. Vamos definir a ortogonalidade como vetores que formam um ângulo de 90 entre eles, ou seja,  $\hat{i} \perp \hat{j}$ ,  $\hat{j} \perp \hat{k}$  e  $\hat{i} \perp \hat{k}$ , onde o símbolo  $\perp$  significa que um vetor é perpendicular ou ortogonal a outro.

### 2.2 Sistemas de Coordenadas Cartesianas

O espaço cartesiano é construído por vetores unitários ortogonais entre si. Normalmente estes são chamados  $\hat{i}$ ,  $\hat{j}$  e  $\hat{k}$ . Sendo relacionados aos eixos x, y e z, respectivamente. De forma mais simples, podemos dizer que o sistema cartesiano é uma ferramenta que nos auxilia a encontrar um objeto ou grupo de informações em um espaço de até n-dimensões. O Sistema de Coordenadas Cartesianas é largamente usado por diversas áreas como matemática, física e astronomia, além de outras, como a química.

#### 2.2.1 Reta dos reais ( $\mathbb{R}$ )


A reta do conjunto dos Reais ( $\mathbb{R}$ ) é o espaço que compreende a primeira dimensão. Nele temos somente as operações simples já conhecidas na álgebra. A distância entre pontos, por exemplo, sempre é trivial, como veremos abaixo. Podemos representar um vetor na reta dos reais como um **segmento orientado da reta**.



Note que, o valor 0 divide a reta dos reais, negativos para a esquerda ( $\leftarrow$ ) e para a direita, os positivos ( $\rightarrow$ ).

#### 2.2.2 Espaço Bidimensional ( $\mathbb{R}^2$ )

No espaço bidimensional, vemos o básico da geometria, a distância entre dois pontos, ou operações de vetores não são mais tão simples, mas na maioria das vezes envolvem somente o Teorema de Pitágoras ou outras operações também bastante conhecidas.




Perceba também que o espaço bidimensional é composto por duas Retas Reais, que possuem uma interseção, determinada como **origem**, suas coordenadas são definidas como  $x = 0$  e  $y = 0$ ,

ou simplesmente o par de coordenadas  $(0,0)$ . Note também que esse espaço bidimensional pode ser tratado também como um **Plano infinito**. Além disso, em um espaço bidimensional podemos definir 4 quadrantes fundamentais:

- Quadrante  $x+, y+$
- Quadrante  $x+, y-$
- Quadrante  $x-, y+$
- Quadrante  $x-, y-$

### 2.2.3 Espaço Tridimensional ( $\mathbb{R}^3$ )

No espaço tridimensional avançamos mais um passo de complexidade, porém ainda temos um objeto de estudo facilmente compreensível espacialmente para o cérebro humano. Podemos resolver muitas situações ainda utilizando o Teorema de Pitágoras.



Ao avançarmos a complexidade do espaço, note que podemos interpretar um ponto em seu espaço como  $(x,y,z)$ . Note que um espaço tridimensional é composto por retas, geradas a partir da interseção de 3 planos, uma ideia que será explicada mais à frente, que são:

- $(0, y, z)$  ;
- $(x, 0, z)$  ;
- $(x, y, 0)$  .

**Espaços  $n$ -dimensionais:** Falando em  $n$ -dimensões temos situações que fogem da compreensão humana (tente imaginar um hipercubo em 4 dimensões, por exemplo), tratamos esses exemplos, na maioria das vezes, de forma puramente matemática, e é então onde a álgebra linear é mais aplicada, já que a maioria dos problemas reais que encontraremos possuem inúmeras variáveis independentes de entrada com uma ou mais saídas.

## 2.3 Sistema de Coordenadas Esféricas e Cilíndricas

Não precisamos necessariamente tratar uma posição no espaço tridimensional (ou em quaisquer  $n$ -dimensões) de forma cartesiana  $(x, y, z)$ . Podemos, utilizar de ângulos para adquirir o mesmo resultado, como por exemplo no sistema de coordenadas esféricas  $(r, \alpha, \theta)$ , que se referem ao raio, ou distância da origem ao ponto, ângulo num primeiro plano e ângulo no segundo plano.




Figura 1: Coordenadas Esféricas

Já no sistema cilíndrico temos  $(r, Z, \theta)$ , onde  $r$  é a distância do ponto a origem no primeiro plano,  $Z$  a “altura” ou a distância ortogonal do ponto ao segundo plano e  $\theta$  o ângulo no primeiro plano.




Figura 2: Coordenadas Cilíndricas

## 2.4 Pontos, Retas e Planos

### 2.4.1 Pontos

Começamos com o objeto mais simples, o ponto, sendo este com função de determinar localização no espaço, porém com dimensão **nula** (0), ou seja, por definição, podemos dizer que um ponto não possui **Volume**, **Área** ou **Comprimento**.




Figura 3: Gráfico de Pontos

### 2.4.2 Retas

$$ax + b = y$$

As retas são conjuntos de pontos, de tal forma que não formem uma curva. Dentro dessas retas, podemos calcular a distância entre eles, agora definindo um **segmento de reta** entre eles. Encontramos as retas, muitas vezes, como a equação vista acima,  $ax + b = y$ , essa forma é como veremos bem comum no cálculo de regressões, um tópico de muita importância.




Figura 4: Gráfico da Reta e sua composição de pontos

### 2.4.3 Planos

O plano é um conjunto de retas e pontos, de modo que apenas um único plano passa por duas retas paralelas não coincidentes.




Figura 5: Planos principais

Outra forma de definir um plano é a partir de uma reta e um ponto não coincidentes (i.e. o ponto não pertence à reta). Podemos ter num plano infinitas retas e pontos. De modo contrário aos últimos dois itens, a interseção entre dois planos não paralelos gera uma única reta. Entre três planos define-se um único ponto ou três retas, dependendo da forma que se encontrarem.

## 2.5 Distância

### 2.5.1 Distância Euclidiana

Essa é a forma mais usual de se calcular a distância entre dois pontos, normalmente calculamos (muitas vezes sem nem se dar conta) com a decomposição do vetor posição em planos e com o uso sequencial do Teorema de Pitágoras. O cálculo da distância euclidiana é dado a partir da generalização do teorema para  $n$  dimensões, mostrado na seguinte expressão:

$$d(P, Q) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Sendo,

$$P = (x_1, x_2, x_3, \dots, x_n)$$

$$Q = (y_1, y_2, y_3, \dots, y_n)$$

Onde  $n$  é o número de dimensões. Então, podemos definir os seguintes casos mais utilizados:

- **Unidimensional:**

$$d(P, Q) = \sqrt{(x_1 - y_1)^2} = |x_1 - y_1|$$

- **Bidimensional:**

$$d(P, Q) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

- **Tridimensional:**

$$d(P, Q) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2}$$


$\vdots$

- **n-dimensional:**

$$d(P, Q) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2 + \dots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

### 2.5.2 Distância Manhattan

Também é conhecida como geometria do táxi.



Imagine um táxi se movendo por uma cidade, a distância prática entre 2 pontos não é a reta que os liga, mas sim quantos quarteirões no eixo  $x$  mais a quantidade de quarteirões no eixo  $y$  o táxi percorreu.

Definimos  $P_0$  como o vetor posição inicial e  $P_1$  o vetor posição final.

- **Unidimensional:** Defina  $P_0 = (x_0)$  e  $P_1 = (x_1)$

$$d(P_0, P_1) = |x_1 - x_0|$$

- **Bidimensional:** Defina  $P_0 = (x_0, y_0)$  e  $P_1 = (x_1, y_1)$ , então

$$d(P_0, P_1) = |x_1 - x_0| + |y_1 - y_0|$$

- **Tridimensional:** Defina  $P_0 = (x_0, y_0, z_0)$  e  $P_1 = (x_1, y_1, z_1)$

$$d(P_0, P_1) = |x_1 - x_0| + |y_1 - y_0| + |z_1 - z_0|$$

$\vdots$

- **n-dimensional:** Defina  $P_0 = (x_0, y_0, \dots, w_0)$ ,  $P_1 = (x_1, y_1, \dots, w_1)$

$$d(P_0, P_1) = |x_1 - x_0| + |y_1 - y_0| + |z_1 - z_0| + \dots + |w_1 - w_0|$$

### 3 Métricas de avaliação de modelos

#### 3.1 Métricas de avaliação de modelos de Regressão

Vimos mais definições e mais fórmulas, e agora vamos a questão de onde iremos utilizar. Abaixo veremos alguns meios de avaliação do modelo de regressão visto na última seção. Para as métricas abaixo, vamos utilizar a **distância euclidiana**.

##### 3.1.1 Coeficiente de Determinação ( $R^2$ ):

O R-quadrado avalia a variabilidade da variável dependente (Y) que é explicada pelo nosso modelo, baseado na variável independente (X). Nele temos  $\bar{Y}$ , que é a média dos valores dependentes da nossa base:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$y_i$ , cada valor real da variável dependente e  $\hat{y}_i$  cada valor estimado para y.

$$R^2 = 1 - \frac{\sum_{i=1}^n |y_i - \hat{y}_i|^2}{\sum_{i=1}^n |y_i - \bar{y}|^2}$$

##### 3.1.2 Erro Quadrático Médio (MSE):

O MSE é a métrica muito utilizada, baseado na distância da estimativa do nosso modelo baseado nos verdadeiros valores dos dados, dado da seguinte forma:

$$MSE = \frac{1}{n} \cdot \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \cdot d(Y, \hat{Y})^2$$

Onde Y é o vetor formado pelos valores da variável dependente e  $\hat{Y}$  os valores estimados por nosso modelo. Por fim  $n$  é a dimensão, ou a quantidade dos valores de Y, ou seja,  $Y = (y_1, y_2, \dots, y_n)$  e  $\hat{Y} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n)$ .

##### 3.1.3 Raiz do Erro Quadrático Médio (RMSE):

Como forma de correção de unidade de medida, a RMSE surge, corrigindo este fator da unidade de medida. Assim como o anterior, ambos penalizam estimativas fora da realidade. Um exemplo desta correção é dado da seguinte forma: Digamos que temos um modelo que quer estimar o gasto em reais de uma família, dado o número de membros, supondo uma linearidade nessa dependência, digamos que o nosso MSE é igual  $MSE = \frac{1}{n} \cdot d(Y, \hat{Y})^2 = (143,00 \text{ reais})^2$ . Perceba que tanto o valor e a unidade de medida dele está elevado ao quadrado, para isso temos o RMSE, retirando a raiz desse valor, e deixando o erro como mesma unidade de medida que Y.

$$RMSE = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (y_i - \hat{y}_i)^2} = \sqrt{\frac{1}{n} \cdot d(Y, \hat{Y})^2} = \frac{1}{\sqrt{n}} \cdot |d(Y, \hat{Y})|$$

### 3.1.4 Erro Absoluto Médio (MAE):

É a média das distâncias entre os valores preditos ( $\hat{Y}$ ) e reais ( $Y$ )

$$MAE = \frac{1}{n} \cdot \sum_{i=1}^n |y_i - \hat{y}_i| = \frac{1}{n} \cdot \sum_{i=1}^n d(y_i, \hat{y}_i)$$

## 3.2 Exercícios

### 3.2.1 Distância Euclidiana

Determine as distâncias entre os pontos pelo método Euclidiano

- P(1, 2) e Q(3, 3)

Resolução:

Um modo simples é calcular as distâncias de cada eixo (assim como em Manhattan)  $|(1, 2) - (3, 3)| = (2, 1)$ . agora utilizamos Pitágoras:  $d = \sqrt{2^2 + 1^2}$ , ou seja,  $d = 5$ .

Ou simplesmente  $d = \sqrt{(P_x - Q_x)^2 + (P_y - Q_y)^2}$ , então  $d = \sqrt{(1 - 3)^2 + (2 - 3)^2}$

- P(3, 0, 5) e Q(1, 0, 2)
- P(1, 0, 1) e Q(-2, 0, -1)
- P(1, 2, 3, 4) e Q(3, 3, 0, 3)
- P(3, -1, 0, 2) e Q(1, 1, 4, 1)

### 3.2.2 Distância Manhattan

Determine agora as distâncias entre os mesmos pontos pelo método Manhattan

- P(1, 2) e Q(3, 3)

Resolução:

Como foi visto  $|(1, 2) - (3, 3)| = (2, 1)$ . Agora somamos os 2 valores,  $d_M = 2 + 1 = 3$

Ou simplesmente  $d_M = |P_x - Q_x| + |P_y - Q_y|$ , então  $d_M = |1 - 3| + |2 - 3|$

- P(3, 0, 5) e Q(1, 0, 2)
- P(1, 0, 1) e Q(-2, 0, -1)
- P(1, 2, 3, 4) e Q(3, 3, 0, 3)
- P(3, -1, 0, 2) e Q(1, 1, 4, 1)

### 3.2.3 Modelo para avaliação

Utilizando os valores da regressão da seção anterior:

$$Y = \begin{vmatrix} 8.1 \\ 6.8 \\ 7.0 \\ 7.4 \\ 7.7 \\ 7.5 \\ 7.6 \\ 8.0 \end{vmatrix} \quad \hat{Y} = \begin{vmatrix} 7.4 \\ 7.3 \\ 7.4 \\ 7.2 \\ 7.8 \\ 7.6 \\ 7.5 \\ 7.8 \end{vmatrix}$$

Encontre os valores:

- $R^2$
- MSE
- RMSE
- MAE

## 4 Introdução a Funções

### 4.1 Definição de função

Uma função é uma relação entre dois conjuntos, com uma determinada lei de correspondência dos elementos de um conjunto para com o outro. Podemos definir matematicamente uma função da seguinte forma: Dados os conjuntos  $A$  e  $B$ , definimos uma  $f$  como uma lei de associação entre elementos de  $A$  ( $x \in A$ ) para com  $B$  ( $y \in B$ ), tal que:

$$\begin{aligned} f : A &\longrightarrow B \\ x &\longrightarrow y \end{aligned}$$

Podemos definir  $y$  como  $y = f(x)$ , ou seja, denotamos  $y$  como uma função de  $x$ .

### 4.2 Domínio, Imagem e Contradomínio

As funções matemáticas são compostas por 3 importantes elementos: domínio, contradomínio e imagem. O domínio, denotado por  $D$ , representa os elementos do conjunto de partida de uma determinada função, isto é, os valores que o  $x$  pode assumir. A imagem, por sua vez, denotada por  $Im$ , representa o conjunto destino de elementos da função. Tal relação pode ser verificada na Figura 6 abaixo.




Figura 6: Exemplo de domínio e imagem de uma função.

Já o contradomínio de uma função, representado por  $Cd$ , representa os possíveis valores de chegada de uma função  $f$ , ou seja, os valores contidos na imagem de  $f$ . Em outras palavras, por exemplo, a Figura 6 é composta pelo domínio  $D(f) = \{-3, 1, 2, 3\}$ , pela imagem  $Im(f) = \{1, 4, 9\}$  e pelo contradomínio  $Cd(f) = \{1, 4, 5, 9\}$ .

### 4.3 Tipos de funções

As funções podem ser classificadas de três formas distintas: função **injetora**, **bijetora** e **sobrejetora**. A seguir, iremos definir cada uma delas e fornecer alguns exemplos.

#### 4.3.1 Função injetora ou injetiva

Uma função é injetora quando cada elemento do domínio  $D$  está relacionado a apenas um elemento da imagem  $Im$ , ou seja, para cada  $x$  existe um único  $f(x)$  associado. A Figura 7 abaixo exemplifica uma função injetiva.




Figura 7: Exemplo de uma função injetiva.

Perceba que cada elemento do contradomínio  $Cd$  é atingido uma única vez.



#### 4.3.2 Função sobrejetora ou sobrejetiva

Quando todos os elementos do domínio  $D$  de uma função estão associados a um elemento da imagem  $Im$ , isto é, quando cada elemento do contradomínio  $Cd$  é atingido pelo menos uma vez, dizemos que a função é sobrejetora. A Figura 8 elucida o que acabamos de definir.




Figura 8: Exemplo de uma função sobrejetora.

#### 4.3.3 Função bijetora ou bijetiva

Quando uma função é injetora e sobrejetora ao mesmo tempo, ou seja, quando cada elemento do contradomínio  $Cd$  é atingido exatamente uma vez, dizemos que ela é bijetora. Podemos visualizar tal definição na Figura 9.




Figura 9: Exemplo de uma função bijetora.

#### 4.3.4 Paridade de um função

Vamos definir os seguintes conjuntos,  $A$  e  $B$  tal que:

$$f : A \longrightarrow B$$

$$x \longrightarrow y$$

Onde temos que  $y$  é função de  $x$ , ou seja,  $f(x) = y$

- **Função Par:** Uma função é denominada par se: (Repare na figura 10)

$$f(x) = f(-x)$$

- **Função Ímpar:** Uma função é denominada ímpar se: (Repare na figura 11)

$$f(-x) = -f(x)$$




Figura 10:  $f(x) = f(-x)$




Figura 11:  $f(-x) = -f(x)$

#### 4.3.5 Função linear

Uma função linear é definida pela seguinte lei de associação:

$$f(x|\beta_1, \beta_0) = \beta_1 \cdot x + \beta_0$$

Podemos interpretar o valor de  $\beta_1$  como o nosso coeficiente angular da reta, ou seja, valor que determina a angulação da reta com relação ao eixo  $x$  e o valor de  $\beta_0$  é o intercept da reta, quando temos  $x = 0$ . Perceba que podemos perceber 3 comportamentos distintos dessa função, eles são os seguintes:

- **Função linear crescente:** quando  $\beta_1 > 0$ , temos um comportamento crescente, como visto na Figura 12 (a medida que aumentamos  $x$ , aumentamos  $y$  de forma proporcional).
- **Função linear decrescente:** quando  $\beta_1 < 0$ , temos um comportamento decrescente, como visto na Figura 13 (a medida que aumentamos  $x$ , diminuímos  $y$  de forma proporcional).




Figura 12: Função linear crescente ( $\beta_1 > 0$ )




Figura 13: Função linear decrescente

- **Função linear constante:** quando  $\beta_1 = 0 \Rightarrow f(x) = \beta_0$ , temos um comportamento constante (a medida que aumentamos x, y permanece inalterado).




Figura 14: Função linear decrescente

#### 4.3.6 Função exponencial

A função exponencial é dado pela seguinte lei de associação:

$$f(x|\alpha) = \alpha^x$$

Esse tipo de função é largamente utilizado para modelar problemas da área de finanças, onde sua base ( $\alpha$ ) pode ser qualquer valor dos reais maiores que 0 ( $\alpha > 0$ ), porém se divide em dois intervalos,  $0 < \alpha < 1$  e  $\alpha > 1$ .

- **Função exponencial crescente** ( $\alpha > 1$ )




Figura 15:  $\alpha > 1$

- **Função exponencial decrescente** ( $0 < \alpha < 1$ )




Figura 16:  $0 < \alpha < 1$

#### 4.3.7 Função logarítmica

A função logarítmica possui a seguinte lei de associação:

$$f(x|a) = \log_a(x)$$

Esta função possui um domínio nos números Reais estritamente positivos e diferentes de 0, ou seja,  $x \in R_+^*$ . Além disso, seu valor de  $a$  deve ser positiva e diferente de 1. Podemos notar dois comportamentos dessa curva, um para  $a > 1$  e um para  $0 < a < 1$ .

- **Função logarítmica crescente:** ( $a > 1$ )




Figura 17:  $a > 1$

- **Função logarítmica decrescente:** ( $0 < a < 1$ )




Figura 18:  $0 < a < 1$

## 4.4 Gráfico de funções

O gráfico de uma função definido no plano cartesiano nos ajuda a representar a ordenação de um conjunto de pontos  $(x, y)$ , onde para cada  $x$ , existe um único valor para  $y = f(x)$ , note que  $x$  varia no domínio de  $f$ .

- **Exemplo (1):** Perceba que o gráfico abaixo é gráfico de função, note que para cada valor de  $x$  existe um único valor para  $f(x)$ .




Figura 19: Gráfico de uma função linear crescente

- **Exemplo (2):** Perceba que o gráfico abaixo não é gráfico de uma função e sim gráfico de uma circunferência, note que para pelo menos um valor de  $x$  no domínio de  $f$ , temos 2 valores para  $f(x)$ .




Figura 20: Gráfico de circunferência

## 4.5 Funções compostas

### 4.5.1 Composição de funções

Vamos definir as seguintes funções, dados os conjuntos  $A, B, C$  e  $D$ , tal que:

$$\begin{aligned} f : A &\longrightarrow B \\ x &\longrightarrow f(x) \end{aligned}$$

e,

$$\begin{aligned} h : C &\longrightarrow D \\ x &\longrightarrow h(x) \end{aligned}$$

Então definimos a composta de  $f$  com  $h$ , supondo  $Im(h) \subset Dom(f)$ , da seguinte forma, podemos dizer que  $f$  e  $h$  são compostas se:

$$(f \circ h) = f(h(x))$$

de maneira análoga, podemos perceber que, supondo  $Im(f) \subset Dom(h)$ , então, podemos dizer que  $f$  e  $h$  são compostas se:

$$(h \circ f) = h(f(x))$$

#### 4.5.2 Associatividade da composição

Vamos definir três funções, tais que  $f : A \longrightarrow B$ ,  $g : B \longrightarrow C$  e  $h : C \longrightarrow D$ . A propriedade da associatividade da composição nos diz que:

$$(h \circ g) \circ f = h \circ (g \circ f)$$

portanto, podemos dizer que  $h \circ g \circ f : A \longrightarrow D$ .

Algumas definições são importantes sabermos:

- **Definição (1):** Sejam  $f$  e  $g$  duas funções bijetoras e  $g$  é a inversa de  $f$ , então  $g(x) = f^{-1}(x)$ ;
- **Definição (2):** Se  $f$  e  $g$  são funções sobrejetoras, então  $g \circ f$  é sobrejetora;
- **Definição (3):** Se  $f$  e  $g$  são funções injetoras, então  $g \circ f$  é injetora.

## 4.6 Exemplos

Uma das áreas que mais usa funções em suas entrelinhas é a Inteligência Artificial. Em relação à arquitetura das redes neurais artificiais (RNAs), o primeiro passo no processamento fica a cargo das **funções de soma**, que são responsáveis pela multiplicação das entradas pelos pesos dos neurônios correspondentes. Uma vez finalizado o cálculo da função soma, o valor é passado para a **função de ativação**, responsável pela introdução da não-linearidade no processamento das RNAs.

Dentre várias funções de ativação existentes, iremos falar de duas: a **função sigmoide** e a **função softmax**.

A função sigmoide, dada pela equação

$$f(x) = \frac{1}{1 + e^{-x}}$$

recebe o valor calculado pela função de soma e retorna um valor que se encontra entre 0 e 1, como pode ser observado na Figura 21.




Figura 21: Gráfico da função sigmoide.

A função softmax, por sua vez, é dada pela equação

$$f(x_j) = \frac{e^{x_j}}{\sum_{i=1}^n e^{x_i}}, \text{ com } i = 1, 2, \dots, j-1, j, j+1, \dots, n-1, n$$

Ela é muito utilizada em problemas envolvendo classificação multiclasse. Uma vez recebendo o resultado da função de soma, a mesma retorna uma distribuição de probabilidade para cada classe existente; a soma dessa distribuição é igual a 1. A Figura 22 representa o gráfico da função softmax.




Figura 22: Gráfico da função softmax.

## 4.7 Exercícios

### 4.7.1 Exercício: Regressão Logística

Sejam as seguintes funções  $g(X) = X \cdot \beta$  e  $f(x) = \frac{1}{1+e^{-x}}$ . Encontre  $f \circ g(x)$ .

**Resolução :** Para resolvermos esse problema, é simples, queremos encontrar uma função composta, dada por  $h(x) = f \circ g(x) = f(g(x))$ , então simplesmente precisamos substituir o valor de  $x$  em  $f(x)$  pela função  $g(x)$ , da seguinte forma:

$$h(x) = f(g(x)) = \frac{1}{1 + e^{-g(x)}}$$

onde  $g(X) = X \cdot \beta$ , então,

$$h(x) = f(X \cdot \beta) = \frac{1}{1 + e^{-X \cdot \beta}}$$

**Observação :** Além disso, note que  $g(x)$  é a função da regressão linear múltipla, ou seja,  $X \cdot \beta$  é um produto matricial, onde cada observação  $y_i = h(x_i)$  pode ser denotado da seguinte forma:

$$f(x_i) = \beta_0 + \beta_1 \cdot x_{i1} + \beta_2 \cdot x_{i2} + \dots + \beta_p \cdot x_{ip}$$

então, por fim temos  $h(x)$  da seguinte forma, para cada observação em  $y$ :

$$h(y_i | \beta_0, \beta_1, \dots, \beta_p) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot x_{i1} + \beta_2 \cdot x_{i2} + \dots + \beta_p \cdot x_{ip})}}$$

Perceba que temos a cara da **função logística** no final. Além disso, para a estatística, a função  $g(X) = g(\mu_i) = X_i \cdot \beta$  é conhecida como **função de ligação** largamente usada para associação dos valores esperados da resposta aos preditores lineares no modelo, utilizado principalmente dentro da classe de **Modelos Lineares Generalizados (GLM)**.



#### 4.7.2 Exercício: Paridade de função

Defina a paridade das funções abaixo:

1.  $f(x) = \frac{1}{1+e^{-x}}$  | **Resolução:** Perceba que  $f(x) \neq f(-x)$  e  $f(-x) \neq -f(x)$ , logo a função não é par, nem ímpar.
2.  $f(x) = x^3$
3.  $f(x) = \sqrt{|x| + 17}$
4.  $f(x) = \frac{1}{x^2 - 1}$

#### 4.7.3 Exercício: Domínio de função

Defina o domínio das funções abaixo:

1.  $f(x) = \frac{1}{x^2 - 1}$  | **Resolução:**  $Dom(f) = \{x \in \mathbb{R} : |x| \neq 1\}$  ou  $Dom(f) = (-\infty, -1) \cup (-1, 1) \cup (1, \infty)$ , ou seja, domínio de  $f$  é os Reais, diferente de  $-1$  e  $1$
2.  $f(x) = \frac{1}{1+e^{-x}}$
3.  $f(x) = x^3$
4.  $f(x) = \sqrt{|x| + 17}$

#### 4.7.4 Exercício: Contradomínio de função

Defina o domínio das funções abaixo:

1.  $f(x) = \frac{1}{1+e^{-x}}$  | **Resolução:**  $Cd(f) = \{x \in \mathbb{R} : 0 < f(x) < 1\}$  ou  $Cd(f) = (0, 1)$ , ou seja, o contradomínio de  $f$  é o intervalo de  $0$  a  $1$ .
2.  $f(x) = \frac{1}{x^2 - 1}$
3.  $f(x) = x^3$
4.  $f(x) = \sqrt{|x| + 17}$

#### 4.7.5 Exercício: Composição de funções

Calcule as funções compostas a seguir:

1. Seja  $f(x) = \frac{x^2 - 1}{x - 1}$  e  $g(x) = x + 1$ , defina  $h(x) = f \circ g(x) = f(g(x))$ . | **Resolução:** Vamos substituir  $g$  dentro de  $f$ , ou seja, avaliar  $g$  em  $f$ . Então:

$$h(x) = f(g(x)) = \frac{g^2(x) - 1}{g(x) - 1} = \frac{(x + 1)^2 - 1}{x + 1 - 1} = \frac{(x + 1)^2 - 1}{x}$$

2. Seja  $f(x) = x^2$  e  $g(x) = \frac{1}{x}$ , defina  $h(x) = f \circ g(x) = f(g(x))$ .
3. Seja  $f(x) = \frac{1}{1+e^{-x}}$  e  $g(x) = \theta \cdot (x - \mu)$ , defina  $h(x) = f \circ g(x) = f(g(x))$ .
4. Seja  $f(x) = \frac{1}{\sqrt{2 \cdot \pi}} \cdot \exp \{ -(x - \mu)^2 \}$  e  $g(x) = x + \mu$ , defina  $h(x) = f \circ g(x) = f(g(x))$ .