

---

# INTRODUÇÃO À MATEMÁTICA E IA

Exercícios: Geometria Analítica


Diretoria de Matemática

Diretor: Manuel F. Junior

Membro: Yann N. G. Nóbrega

`tail.ufpb@gmail.com`

`https://aria.ci.ufpb.br/tail/`



# Sumário

## Ponto, Reta e Plano

Exemplo

Exemplo

Exemplo

## Distância Euclidiana

## Distância Manhattan

Exemplos

## Métodos de Avaliação de Regressão

$R^2$

MSE

RMSE

MAE

Aplicação Prática




# Ponto, Reta e Plano

- ▶ **Pontos:** Começamos com o objeto mais simples, o ponto, sendo este com função de determinar localização no espaço, porém com dimensão **nula** (0), ou seja, por definição, podemos dizer que um ponto não possui **Volume**, **Área** ou **Comprimento**.



# Ponto



**Figura:** Gráfico de pontos em um espaço bidimensional



# Ponto, Reta e Plano


## ► Retas:

$$ax + b = y$$

As retas são conjuntos de pontos, de tal forma que não formem uma curva. Dentro dessas retas, podemos calcular a distância entre eles, agora definindo um **segmento de reta** entre eles. Encontramos as retas, muitas vezes, como a equação vista acima,  $ax + b = y$ , essa forma é como veremos bem comum no cálculo de regressões, um tópico de muita importância.



# Reta



**Figura:** Gráfico da Reta e sua composição de pontos




# Ponto, Reta e Plano

- ▶ **Planos:** O plano é um conjunto de retas e pontos, de modo que apenas um único plano passa por duas retas paralelas não coincidentes. Outra forma de definir um plano é a partir de uma reta e um ponto não coincidentes, ou seja, o ponto não pertence à reta. Podemos ter num plano infinitas retas e pontos. De modo contrário aos últimos dois itens, a interseção entre dois planos não paralelos gera uma única reta. Entre três planos define-se um único ponto ou três retas, dependendo da forma que se encontrarem.



# Plano



**Figura:** Planos principais





# Distância Euclidiana

- ▶ A distância Euclidiana será a mais utilizada!
- ▶ Muitos a conhecem, no plano, como Teorema de Pitágoras.
- ▶ Na 3° ou maiores dimensões utilizamos o Teorema várias vezes.
- ▶ Vamos mostrar a generalização para  $n$  dimensões



# Distância Euclidiana

Essa é a forma mais usual de se calcular a distância entre dois pontos, normalmente calculamos (muitas vezes sem nem se dar conta) com a decomposição do vetor posição em planos e com o uso sequencial do Teorema de Pitágoras. O cálculo da distância euclidiana é dado a partir da generalização do teorema para  $n$  dimensões, mostrado na seguinte expressão:

$$d(P, Q) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Sendo,  $P = (x_1, x_2, x_3, \dots, x_n)$  e  $Q = (y_1, y_2, y_3, \dots, y_n)$ . Onde  $n$  é o número de dimensões.



# Distância Euclidiana

- ▶ **Unidimensional:** para o caso unidimensional ( $n = 1$ ), temos o mais trivial, onde calculamos a distância entre dois pontos. Pela fórmula, temos o seguinte:

$$d(P, Q) = \sqrt{(x_1 - y_1)^2} = |x_1 - y_1|$$

Sendo  $P = x_1$  e  $Q = y_1$ .



# Distância Euclidiana


- **Bidimensional:** Para o caso bidimensional ( $n = 2$ ), a fórmula torna-se uma junção aplicação mais ampla do teorema de Pitágoras, tal que:

$$d(A, B) = d_{AB} = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

Sendo  $A = (x_1, x_2)$  e  $B = (y_1, y_2)$ .



# Distância Euclidiana



# Distância Euclidiana


- ▶ **Tridimensional:** Para o caso tridimensional ( $n=3$ ), devemos utilizar uma forma ainda mais geral para o teorema de Pitágoras, dado por:

$$d(P, Q) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2}$$

Onde  $P = (x_1, x_2, x_3)$  e  $Q = (y_1, y_2, y_3)$




# Distância Euclidiana



# Distância Manhattan

- ▶ Também conhecida como **geometria do táxi**.




**Figura:** Distância Manhattan e Euclidiana





# Distância Manhattan

- ▶ A distância prática entre 2 pontos não é a reta que os liga
- ▶ Quantas unidades no eixo x mais a quantidade no eixo y.



**Figura:** Distância Manhattan e Euclidiana



# Distância Manhattan

$$d(P_0, P_1) = |P_1 - P_0|$$

$$P_0 = (x_0, y_0, z_0, \dots, w_0)$$

$$P_1 = (x_1, y_1, z_1, \dots, w_1)$$

$$d(P_0, P_1) = |x_1 - x_0| + |y_1 - y_0| + |z_1 - z_0| + \dots + |w_1 - w_0|$$



# Distância Manhattan

Qual a distância Manhattan entre os pontos:

$$P_1 = (0, 3, 7) \text{ e}$$

$$P_2 = (4, 0, -5)$$



# Exemplos

- Utilizamos a definição da distância:

$$d(P_0, P_1) = |0 - 4| + |3 - 0| + |7 - (-5)|$$

$$d(P_0, P_1) = |4 + 3 + 12|$$

- Ou, combinando as duas contas antes de operar:

$$d(P_0, P_1) = 19$$



# A Regressão

Esquema	Nº Ataques	Duração	Índice
A	5	118	8.1
B	13	132	6.8
C	20	119	7.0
D	28	153	7.4
E	41	91	7.7
F	49	118	7.5
G	61	132	7.6
H	62	105	8.0



# Métodos de Avaliação de Regressão

$$Y = \begin{bmatrix} 8.1 \\ 6.8 \\ 7.0 \\ 7.4 \\ 7.7 \\ 7.5 \\ 7.6 \\ 8.0 \end{bmatrix}$$

$$\hat{Y} = \begin{bmatrix} 7.4 \\ 7.3 \\ 7.4 \\ 7.2 \\ 7.8 \\ 7.6 \\ 7.5 \\ 7.8 \end{bmatrix}$$

Vamos encontrar os seguintes valores:

- ▶  $R^2$
- ▶ MSE
- ▶ RMSE
- ▶ MAE



# Coefficiente de Determinação ( $R^2$ )

- ▶ Avalia a variabilidade da variável dependente (Y) que é explicada pelo nosso modelo, baseado na variável independente (X).
- ▶ Definimos  $\bar{y}$ ,  $y_i$  e  $\hat{y}_i$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

- ▶ O  $R^2$  é então:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{d(\hat{Y}, Y)^2}{d(Y, \bar{Y})^2}$$



## Coefficiente de Determinação ( $R^2$ )

$$\bar{y} = \frac{(8.1 + 6.8 + 7.0 + 7.4 + 7.7 + 7.5 + 7.6 + 8.0)}{8} = 7.5125$$

$$num = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 1.01$$

$$den = \sum_{i=1}^n (y_i - \bar{y})^2 = 1.408755$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 0.2830524$$





# Erro Quadrático Médio (MSE):

- ▶ O MSE é a distância da estimativa do nosso modelo para os valores verdadeiros dos dados, da seguinte forma:

$$MSE = \frac{1}{n} \cdot d(Y, \hat{Y})^2$$



## Erro Quadrático Médio (MSE):

$$\begin{aligned}MSE &= ((8.1 - 7.4)^2 + (6.8 - 7.3)^2 + (7.0 - 7.4)^2 + (7.4 - 7.2)^2 + \\&+ (7.7 - 7.8)^2 + (7.5 - 7.6)^2 + (7.6 - 7.5)^2 + (8.0 - 7.8)^2) / 8 = 1.01 / 8 \\MSE &= 0.12625\end{aligned}$$



## Raiz do Erro Quadrático Médio (RMSE):

- ▶ A Raiz do MSE é a raiz da distância da estimativa do nosso modelo para os valores verdadeiros dos dados, da seguinte forma:

$$RMSE = \sqrt{\frac{1}{n} \cdot d(Y, \hat{Y})^2}$$



## Raiz do Erro Quadrático Médio (RMSE):

$$RMSE = \sqrt{MSE} = \sqrt{0.12625}$$

$$RMSE = 0.3553$$



# Erro Absoluto Médio (MAE):

- ▶ É a média das distâncias entre os valores preditos ( $\hat{Y}$ ) e reais ( $Y$ ):

$$MAE = \frac{1}{n} \cdot \sum_{i=1}^n |y_i - \hat{y}_i| = \frac{1}{n} \cdot \sum_{i=1}^n d(y_i, \hat{y}_i)$$



## Erro Absoluto Médio (MAE):

$$\begin{aligned} MAE &= (|8.1 - 7.4| + |6.8 - 7.3| + |7.0 - 7.4| + |7.4 - 7.2| + \\ &+ |7.7 - 7.8| + |7.5 - 7.6| + |7.6 - 7.5| + |8.0 - 7.8|)/8 = 2.3/8 \\ MAE &= 0.2875 \end{aligned}$$



# No Python:

- ▶ `from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error`
- ▶ `r2 = r2_score(Y_true, Y_pred)`
- ▶ `mse = mean_squared_error(Y_true, Y_pred)`
- ▶ `rmse = mean_squared_error(Y_true, Y_pred, squared = False)`
- ▶ `mae = mean_absolute_error(Y_true, Y_pred)`

